

Os Efeitos de Transbordamento das Transferências Condicionadas de Renda do Programa Bolsa Família na Redução dos Conflitos Agrários no Brasil*

RICARDO CENEVIVA[†]

Resumo

Este relatório apresenta uma introdução didática e conceitualmente rigorosa ao uso de Sistemas de Informação Geográfica (SIG) na pesquisa sociológica, com foco em métodos exploratórios e aplicações empíricas no contexto brasileiro e latino-americano. O objetivo é esclarecer os fundamentos operacionais dos SIG, suas aplicações no diagnóstico de padrões socioespaciais e sua relevância para o ciclo de políticas públicas. São discutidos os principais conceitos — como modelos vetorial e raster, projeções, vizinhança espacial e autocorrelação — bem como técnicas como cartografia temática, Moran I e LISA. O relatório examina dois estudos exemplares: um sobre desigualdade fundiária e conflito rural (Albertus et al., 2018), e outro sobre queimadas e internações hospitalares no Pantanal (Gonçalves et al., 2025), destacando sua estrutura metodológica e implicações substantivas. Por fim, aborda aspectos éticos e desafios em países de renda média, incluindo LGPD, qualidade dos dados e práticas de ciência aberta. O texto destina-se a estudantes iniciantes em ciências sociais, combinando clareza didática com precisão metodológica.

1 Introdução

Os Sistemas de Informação Geográfica (SIG) são ferramentas computacionais que permitem coletar, armazenar, analisar e visualizar dados com referência geográfica[1]. Em termos simples, um SIG combina software, hardware, dados espaciais e procedimentos analíticos para representar fenômenos na superfície terrestre de forma georreferenciada. Esses sistemas possibilitam mapear elementos do território e espacializar fenômenos sociais, facilitando a identificação de relações, padrões e tendências no espaço[2]. Por exemplo, pesquisadores podem usar SIG para mapear a distribuição de serviços públicos em uma cidade ou visualizar índices socioeconômicos por bairro, contribuindo para o planejamento urbano e a formulação de políticas.

Um conceito-chave em SIG é o de camadas temáticas. Os dados geográficos são organizados em camadas sobrepostas, cada uma contendo um tipo de informação (por exemplo, uma camada de ruas, outra de bairros e outra de dados populacionais)[3][4]. Essa estrutura em camadas permite comparar e combinar informações distintas referentes a um mesmo local, através de procedimentos de sobreposição de mapas (map overlay). Assim, um pesquisador pode, por exemplo, sobrepor um mapa de índices de criminalidade com outro de distribuição de renda para examinar visualmente possíveis coincidências espaciais entre pobreza e violência. Para que outro pesquisador possa reproduzir um mapa feito em SIG, é imprescindível explicitar certas decisões cartográficas: quais camadas de dados foram

*Projeto de pesquisa apresentado à Universidade Federal do ABC (UFABC) como parte do processo seletivo simplificado para contratação de professor visitante na área de Políticas Públicas e subárea de Análise de Políticas Públicas.

[†]Professor de Ciência Política e Políticas Públicas, Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas (CECS), Universidade Federal do ABC (UFABC), phone: 55 21 986 313 444, e-mail: ricardo.ceneviva@ufabc.edu.br.

utilizadas e suas fontes, qual o sistema de projeção e coordenadas empregado, qual método de classificação dos dados foi aplicado na simbologia do mapa e qual a escala ou resolução espacial dos dados. Documentar essas escolhas assegura que os resultados sejam replicáveis e compreendidos em seu contexto técnico.

Modelos de dados geográficos: Em SIG, trabalham-se principalmente com dois modelos de representação de dados espaciais: vetorial e raster (matricial)[5]. No modelo vetorial, as entidades geográficas do mundo real são representadas por pontos, linhas ou polígonos, focando na precisão de sua localização exata no espaço[6][7]. Por exemplo, a localização de escolas pode ser representada por pontos com coordenadas, estradas por linhas e os limites de bairros por polígonos. Já no modelo raster, o espaço é dividido em uma grade regular de células (pixels), onde cada célula armazena um valor representando uma característica naquele local (como altitude, temperatura ou densidade populacional)[8]. Quanto maior o tamanho da célula (menor resolução), menos detalhes espaciais são capturados[9]. Dados raster são apropriados para fenômenos contínuos (e.g. uso do solo, imagens de satélite), enquanto dados vetoriais são indicados para objetos discretos (e.g. localização de equipamentos urbanos). Saber distinguir e escolher entre dados vetoriais e raster é fundamental: na pesquisa sociológica, dados vetoriais costumam modelar unidades como municípios, setores censitários ou regiões administrativas, enquanto dados raster podem representar superfícies como densidade populacional estimada ou índices ambientais que variam continuamente no território.

Projeções cartográficas e sistemas de referência: Todo dado geográfico utiliza um Sistema de Referência de Coordenadas (SRC ou CRS), que define como o globo terrestre (tridimensional) é projetado numa superfície plana (mapa) e como as coordenadas numéricas correspondem a locais no mundo real. A escolha da projeção é uma decisão cartográfica crucial, pois diferentes projeções introduzem diferentes distorções de área, forma, distância ou ângulo. Por exemplo, a projeção de Mercator preserva ângulos (conformidade) mas distorce áreas (regiões próximas aos polos aparecem exageradamente grandes), enquanto projeções equivalentes (como a de Albers equal-area) preservam proporções de área ao custo de distorcer formas. Em análises sociológicas que envolvem cálculo de distâncias ou áreas, a seleção do CRS apropriado afeta diretamente as medidas: um CRS equidistante pode ser preferível se o interesse for medir distâncias exatas (por exemplo, acesso a serviços em quilômetros), já um CRS equivalente é indicado se for importante comparar áreas (por exemplo, comparar densidade demográfica em distintas regiões sem viés de projeção). Portanto, ao elaborar mapas ou análises espaciais rigorosas, deve-se justificar a escolha do CRS, documentando-o (p.ex., “SIG em SAD69 datum, projeção policônica”) e compreender suas implicações métricas – garantindo que comparações de distância e área façam sentido no contexto do fenômeno estudado.

Unidades de análise e MAUP: Na pesquisa espacial, definir claramente a unidade de análise geográfica é essencial. A unidade de análise é o delineamento espacial sobre o qual os dados são agregados ou analisados – pode ser uma divisão administrativa (cidades, estados), uma malha regular (grade quadrada), unidades naturais (bacias hidrográficas) ou zonas definidas pelo pesquisador. Essa escolha deve ser adequada à escala do fenômeno social investigado. Por exemplo, um estudo sobre segregação socioeconômica pode usar setores censitários ou bairros como unidades, pois capturam variações intraurbanas; já um estudo comparando políticas educacionais pode optar por municípios ou estados. Entretanto, é importante reconhecer o Problema da Unidade de Área Modificável (MAUP): resultados estatísticos podem variar conforme a unidade espacial adotada e o nível de agregação dos dados. Em outras palavras, diferentes delineamentos das unidades espaciais podem levar a conclusões diferentes a partir do mesmo dado subjacente[10][11].

Esse problema ocorre em duas dimensões: o efeito de escala, em que análises em escalas maiores ou menores (por exemplo, bairros vs. cidades) produzem resultados distintos; e o efeito de zoneamento, em que diferentes formas de agrupar zonas na mesma escala (por exemplo, redefinir os limites regionais) também alteram os resultados[12]. Uma implicação do MAUP é a falácia ecológica, que consiste em inferir indevidamente comportamentos individuais a partir de dados agregados[13]. Por exemplo, encontrar correlação entre violência e baixa renda em municípios não significa que os indivíduos de baixa renda sejam mais violentos – pode haver outras explicações, e a correlação observada pode ser artefato do nível de agregação[14]. Para mitigar o MAUP, pesquisadores devem testar a robustez das análises em diferentes escalas ou delimitações, além de justificar por que a unidade escolhida é apropriada ao fenômeno (por exemplo, municípios podem ser adequados para analisar políticas públicas que são implementadas municipalmente, ao passo que vizinhanças podem ser melhores para fenômenos comunitários). Sempre que possível, recomenda-se também verificar se padrões detectados persistem com unidades alternativas ou métodos multi-escalas, reforçando a validade dos insights espaciais obtidos.

Vizinhança espacial e matrizes de pesos: Grande parte das análises espaciais quantitativas depende do conceito de vizinhança espacial, que define como cada unidade geográfica relaciona-se com as demais no espaço. Para formalizar essa relação, constrói-se uma matriz de contiguidade ou de pesos espaciais (*spatial weights matrix*), usualmente denotada W . Essa matriz W especifica, para cada par de unidades i, j , um peso que representa o grau de proximidade ou influência entre elas – muitas vezes pesos binários 0/1 indicando se as unidades são vizinhas (1) ou não (0). Existem diferentes critérios para definir "vizinhos". Os dois critérios clássicos de contiguidade em áreas poligonais são conhecidos como padrão Torre (Rook) e Rainha (Queen) – em alusão ao movimento das peças de xadrez. Na contiguidade Rook, duas áreas são vizinhas apenas se compartilham um lado comum (fronteira linear); já na contiguidade Queen, considera-se vizinho qualquer área que toque a outra em pelo menos um ponto, seja lado ou vértice (ou seja, inclui também contatos diagonais)[15].

Assim, a vizinhança do tipo rainha tende a incluir mais vizinhos para cada unidade (até 8 numa grade regular, como os movimentos de uma rainha no tabuleiro), enquanto a do tipo torre inclui os adjacentes ortogonais (até 4, como movimenta a torre). Além da contiguidade direta, outro critério comum é a distância geográfica: define-se um raio (e.g. 50 km) ou um número k de vizinhos mais próximos, e unidades dentro desse limiar recebem peso como vizinhas. Há também matrizes de vizinhança padronizadas (*row-standardized*), em que os pesos de cada linha somam 1, e variantes que atribuem pesos graduados inversamente proporcionais à distância (p.ex., $1/d$ ou $1/d^2$). A construção cuidadosa da matriz de pesos é crucial, pois ela formaliza a suposição de como o espaço importa no fenômeno: por contiguidade administrativa? Por proximidade física? Por similaridade de contexto urbano? Por exemplo, no estudo de difusão de epidemias, pode fazer sentido usar vizinhança por distância (proximidade geográfica), enquanto num estudo de interações entre municípios, a contiguidade administrativa (compartilhar fronteira) pode capturar contatos socioeconômicos regionais. Em todos os casos, é fundamental explicitar o critério de vizinhança escolhido e justificar sua adequação. Essa decisão afeta diretamente métricas como autocorrelação espacial e modelos espaciais – e portanto análises de robustez com diferentes matrizes de pesos podem ser necessárias para verificar se os resultados não são altamente sensíveis a essa escolha.

Exemplo de mapa temático e integração de dados geográficos: Mapa do bioma Pantanal e municípios correspondentes, ilustrando a sobreposição de camadas – limites territoriais e dados populacionais municipais – em um único mapa. Este exemplo, produzido em QGIS e utilizando dados abertos do IBGE, mostra como um SIG permite combinar dados

de diversas fontes (limites oficiais, estatísticas demográficas) para comunicar informação espacial de forma clara[16]. No contexto de pesquisa social, mapas temáticos como este podem revelar padrões regionais (por exemplo, distribuição de população) e servir de base para análises mais complexas.

2 Métodos Exploratórios de Análise Espacial e Diagnóstico Socio-territorial

Uma vez compreendidos os fundamentos de representação espacial, os pesquisadores em ciências sociais empregam métodos exploratórios de análise espacial para identificar padrões e associações nos dados geográficos. Esses métodos, reunidos sob o rótulo de Análise Exploratória de Dados Espaciais (ESDA), oferecem ferramentas para diagnóstico espacial – isto é, para descobrir clusters, outliers e dependências espaciais que possam existir em fenômenos sociais distribuídos no território. Diferentemente de técnicas confirmatórias, os métodos exploratórios visam principalmente a descrição e a geração de hipóteses, não testes causais definitivos. Abaixo, destacamos alguns conceitos e técnicas introdutórias importantes: cartografia temática e classificação, autocorrelação espacial global (Moran I) e indicadores locais de associação espacial (LISA).

Cartografia temática e escolhas de classificação: A confecção de mapas temáticos é geralmente o primeiro passo na exploração de dados espaciais. Um mapa coroplético – aquele em que regiões são preenchidas com cores de acordo com valores de uma variável – pode revelar de imediato desigualdades territoriais ou padrões socioespaciais. Entretanto, um aspecto frequentemente subestimado é que a forma de classificar os dados num mapa coroplético pode alterar significativamente a percepção do padrão. Ao criar um mapa, o analista precisa decidir em quantas classes agrupar os valores e quais pontos de corte utilizar para definir essas classes (por exemplo, quartis, média etc.). Por exemplo, imagine que estamos mapeando a taxa de analfabetismo nos municípios. Se utilizarmos quebras naturais (método de Jenks), os limites entre classes serão escolhidos para maximizar as diferenças entre as classes e minimizar as diferenças dentro delas, possivelmente destacando regiões com valores excepcionais. Se, em vez disso, usarmos quintis (quantis) – de modo que 20% dos municípios caibam em cada classe – o mapa exibirá uma distribuição mais equilibrada de cores, mas valores extremos podem ser "suavizados" dentro de classes amplas. Já uma classificação por intervalos iguais (p.ex. 0–5%, 5–10%, 10–15%, etc.) facilita a comparação com metas ou faixas absolutas, porém pode resultar em muitas regiões na mesma classe se os dados estiverem concentrados numa faixa estreita. Cada técnica de classificação pinta uma história diferente para o leitor do mapa usando os mesmos dados subjacentes[17]. Portanto, encontrar um cluster alto-alto (regiões de valor alto cercadas por outras de valor alto) pode depender da paleta e das quebras utilizadas: escolhas arbitrárias podem exagerar ou ocultar um agrupamento. O analista deve então experimentar diferentes métodos, observar a estabilidade dos padrões e, idealmente, informar qual classificação foi usada e por quê. Além disso, boas práticas incluem normalizar indicadores (e.g. usar taxas em vez de contagens absolutas) e aplicar cores intuitivas (por exemplo, do claro para o escuro indicando do baixo para o alto). Em suma, a cartografia temática é tanto arte quanto ciência, e escolhas conscientes de classificação aumentam a transparência e confiabilidade do diagnóstico espacial.

Autocorrelação espacial global – Índice I de Moran: Um conceito central em análise espacial é o de autocorrelação espacial, que avalia em que medida a distribuição de um fenômeno no espaço apresenta padrões de aglomeração (cluster) ou dispersão. O Índice I de Moran é uma estatística clássica para medir a autocorrelação espacial global de uma variável em todo o mapa. Seus valores variam tipicamente de -1 a +1 (descontando aspectos de

amostragem): valores positivos indicam autocorrelação positiva (unidades vizinhas tendem a ter valores similares, ou seja, padrão em cluster), valor zero indica ausência de correlação espacial (padrão aleatório), e valores negativos indicam autocorrelação negativa (vizinhos tendem a ser muito diferentes, ou seja, padrão de segregação ou tabuleiro de xadrez).

O índice de autocorrelação espacial global de Moran, denotado por I , é frequentemente expresso pela seguinte fórmula:

$$I = \frac{n}{W} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

onde x_i é o valor da variável na unidade i , \bar{x} é a média global da variável, w_{ij} são os elementos da matriz de pesos espaciais W (podendo ser normalizados ou não) e $W = \sum_i \sum_j w_{ij}$ é a soma total dos pesos. Intuitivamente, esse índice compara a covariância espacial — entre cada observação e seus vizinhos — com a variância total da variável. Valores positivos de I sugerem agrupamento espacial (valores semelhantes entre vizinhos), enquanto valores negativos indicam dispersão ou alternância espacial.

Uma maneira didática de interpretar o sinal e a magnitude do Moran I é através do diagrama de dispersão de Moran. Nesse diagrama, coloca-se no eixo horizontal o valor padronizado da variável em cada unidade (desviando da média) e no eixo vertical o valor médio (ou ponderado) dessa variável nas unidades vizinhas — essencialmente $W \times x$, a defasagem espacial. Cada ponto no gráfico representa uma unidade geográfica. Uma reta de regressão ajustada aos pontos tem coeficiente angular igual ao Moran I [18]. Assim, se muitas unidades têm valor alto cercadas por vizinhos de valor alto e unidades de valor baixo cercadas por vizinhos de valor baixo, os pontos se concentrarão no quadrante alto-alto e baixo-baixo, respectivamente, resultando numa inclinação positiva ($I > 0$). Isso sugere a presença de clusters de semelhança — por exemplo, municípios ricos próximos de municípios também ricos, e municípios pobres próximos de outros pobres, indicando disparidades regionais marcantes. Por outro lado, se for comum que unidades altas estejam cercadas de baixas ou vice-versa (pontos nos quadrantes alto-baixo e baixo-alto), a inclinação será negativa ($I < 0$), sugerindo um padrão espacial compensatório ou intercalado (ex.: bolsões de riqueza em meio a pobreza ou outliers espaciais). Sempre é necessário calcular a significância estatística do Moran I — usualmente via teste de permutação aleatória dos valores geográficos — para verificar se o padrão observado difere do acaso.

Um Moran I significativamente positivo autoriza a inferência de que há dependência espacial global (o espaço importa na distribuição daquela variável), enquanto um Moran não significativo indica que, no nível global, não se pode rejeitar a hipótese de distribuição aleatória espacialmente. Importante notar: um Moran significativo não estabelece causas, apenas levanta hipóteses de processos geradores. Por exemplo, ao encontrar autocorrelação espacial positiva em índices de desemprego, pode-se hipotetizar processos de difusão espacial de condições econômicas ou efeitos de contexto regional; no entanto, isso não prova causalidade (pode haver variáveis omitidas influenciando regiões próximas de forma similar). O diagnóstico sugerido por um Moran I alto é “há clusters — investigue-os!”, mas não autoriza afirmar que um fenômeno causa o outro sem análise adicional.

Diagrama de dispersão de Moran: Ilustração de um Moran Scatterplot típico, onde cada ponto representa uma unidade geográfica. As linhas tracejadas dividem os quatro quadrantes (alto-alto, baixo-baixo, alto-baixo, baixo-alto) relativos à média. O coeficiente I de Moran corresponde à inclinação da reta ajustada aos pontos [19][20]. No exemplo esquemático acima (dados de criminalidade em distritos), observa-se muitos distritos no quadrante alto-alto (valor acima da média e vizinhança também acima da média) e baixo-

baixo, refletindo autocorrelação espacial positiva – distritos similares tendem a se agrupar. Esse diagrama auxilia a identificar outliers espaciais: pontos em quadrantes alto-baixo ou baixo-alto (valores destoantes do entorno). Em análise exploratória, mapas e Moran scatterplots são usados em conjunto: o índice global resume o padrão, enquanto a inspeção dos quadrantes e casos individuais permite perguntar que locais estão puxando o padrão e se eles fazem sentido substantivo (por exemplo, uma área de renda alta cercada por áreas de renda baixa pode indicar um enclave de riqueza em região pobre, merecendo atenção específica).

Clusters locais e mapas LISA: Complementando o Moran I global, que resume o padrão em todo o mapa, é muitas vezes útil identificar onde exatamente estão os clusters ou valores discrepantes. Para isso servem os indicadores locais de autocorrelação espacial (LISA), introduzidos por Luc Anselin (1995). O LISA de Moran local (às vezes chamado I_i local) calcula, para cada unidade i , uma estatística que reflete a associação daquele valor com os valores nos vizinhos de i . Em termos simples, podemos pensar que o LISA de i indica quanto a unidade i contribui para o Moran I global. Mais praticamente, os LISAs permitem decompor o padrão: eles identificam clusters de Alto-Alto, clusters de Baixo-Baixo, outliers do tipo Alto-Baixo e Baixo-Alto, de forma estatisticamente significativa. Por exemplo, suponha a taxa de desemprego por município. Um cluster Alto-Alto significa um município com desemprego alto rodeado por municípios também com desemprego alto – isso poderia delinear uma região problemática, talvez um cinturão de estagnação econômica.

Um cluster Baixo-Baixo, por outro lado, indica um bolsão de boas condições (baixa taxa rodeada de baixa taxa). Já um outlier Alto-Baixo pode apontar um município destoante positivamente (ilha de desemprego alto numa área de baixo desemprego, sugerindo um caso isolado a investigar), enquanto um Baixo-Alto seria o inverso (um “oásis” de desemprego baixo circundado por área de alto desemprego). Esses padrões locais são tipicamente representados em um mapa LISA, onde cada área é colorida segundo seu quadrante (alto-alto, etc.) e geralmente marca-se com símbolos as áreas cujo LISA é estatisticamente significativo a um nível escolhido (por exemplo, $p < 0,05$ após correção pelo número de testes). A leitura de um mapa LISA deve ser sempre conceitual: encontrar um cluster alto-alto para uma variável social sugere possíveis processos de homofilia espacial ou influências de fatores regionais comuns; porém, não autoriza imediatamente concluir causalidade. Por exemplo, um cluster de alta mortalidade infantil em municípios adjacentes (alto-alto) certamente aponta a existência de um fenômeno regional a ser explicado – talvez pobreza estrutural ou acesso precário a serviços de saúde numa sub-região – mas o LISA em si não diz qual é a causa, nem se os municípios interagem entre si ou apenas compartilham características.

Ele sugere hipóteses: ex. "será que há uma política pública ausente nessa área?" ou "será uma zona socioeconômica historicamente desfavorecida?". Ao mesmo tempo, o diagnóstico local também não prova que todos municípios do cluster alto-alto sejam iguais – eles podem ter diferenças internas, e o cluster mostra uma tendência geral. Portanto, a função dos métodos exploratórios (Moran global e locais) é diagnosticar padrões espaciais de maneira rigorosa, oferecendo insights que conduzem a perguntas de pesquisa mais refinadas ou apontam para a necessidade de modelos espaciais em etapas subsequentes. Em suma, encontrar um cluster no diagnóstico é ponto de partida, não de chegada: deve-se integrar esse achado ao conhecimento substantivo (por que ali?) e eventualmente testá-lo com dados adicionais ou métodos confirmatórios, evitando a armadilha de confundir padrão com causalidade.

Por fim, vale destacar que as escolhas feitas na etapa exploratória – como o tipo de mapa, método de classificação, definição da vizinhança e tratamento de outliers – podem alterar

a percepção dos padrões. Um exemplo concreto: se dividimos os dados de renda em poucas classes (digamos, apenas "alto" e "baixo"), podemos mascarar variações importantes e até alterar quais clusters aparecem significativos localmente. Já a decisão de normalizar variáveis (por exemplo, casos de doença per capita em vez de números brutos) é essencial para evitar que áreas simplesmente maiores ou mais populosas dominem o mapa. Portanto, o pesquisador deve refletir: “Que escolhas de visualização e medida estou fazendo e como elas influenciam o que vejo?” – isso faz parte do rigor no diagnóstico espacial. Ferramentas computacionais modernas (como GeoDa, ArcGIS, QGIS, R espacial) facilitam a experimentação interativa com esses parâmetros, permitindo checar como as aparências mudam. Essa prática de “sensitivity analysis” informal é altamente recomendada antes de fixar interpretações.

Em síntese, os métodos exploratórios fornecem um olhar inicial estruturado sobre dados espaciais sociológicos: revelam desigualdades regionais, identificam clusters quentes (hotspots) ou frios, sugerem regularidades espaciais que requerem explicação teórica. Na próxima seção, veremos como estudos empíricos concretos empregaram esses conceitos – como Moran e vizinhança – para diagnosticar problemas sociais e embasar políticas públicas, ilustrando a integração entre análise espacial e questões sociológicas substanciais.

3 Aplicações Empíricas

Para tornar os conceitos mais palpáveis, examinaremos dois estudos que utilizaram SIG e lógica de vizinhança de forma exemplar em pesquisas sociais, destacando como formularam perguntas claras, documentaram escolhas espaciais e conectaram seus diagnósticos a implicações de política. Em seguida, faremos uma comparação narrativa entre esses estudos em quatro eixos: (1) pergunta de pesquisa, (2) dados e construção espacial, (3) estratégia de análise e diagnóstico, (4) implicações e limites. Os estudos selecionados são:

- Albertus, Brambor e Ceneviva (2018) – que investigou a relação entre desigualdade fundiária e conflito rural no Brasil, explorando como a presença de programas de reforma agrária em municípios vizinhos afeta a ocorrência de invasões de terra.
- Gonçalves et al. (2025) – que avaliou os efeitos das queimadas no Pantanal sobre internações hospitalares por doenças respiratórias e cardiovasculares, integrando dados ambientais (focos de incêndio, clima, poluição) com dados de saúde pública.

Desigualdade fundiária e conflitos agrários no Brasil (Albertus et al., 2018)

Pergunta e contexto: O estudo de Albertus, Brambor e Ceneviva[21][22] parte de uma questão clássica de sociologia política: qual é a relação entre concentração de terras e ocorrência de conflitos rurais (como invasões de terra por movimentos sociais)? Além disso, pergunta por que programas de reforma agrária – que teoricamente atenuariam conflitos ao redistribuir terras – às vezes agravam os conflitos em vez de mitigá-los[23]. Os autores focam no caso do Brasil entre 1988 e 2013, período marcado por intensa mobilização por reforma agrária e respostas heterogêneas das elites agrárias. A hipótese inovadora deles é que não basta olhar a desigualdade fundiária isoladamente; é preciso entender o contexto espacial de ações de reforma agrária próximas. Em outras palavras, eles investigam se a presença de assentamentos de reforma agrária em municípios vizinhos altera o comportamento de proprietários de terras e invasores em um dado município. Isso já indica uma abordagem espacial: a consideração de eventos em localidades vizinhas como parte da explicação para conflitos locais.

Dados e construção espacial: A unidade de análise escolhida foi o município brasileiro, adequado ao fenômeno pois invasões de terra e assentamentos são contabilizados nessa escala (dados administrativos e de movimentos sociais costumam ser agregados municipalmente). Os autores compilaram um conjunto de dados municipais abrangendo: medidas de desigualdade fundiária (por exemplo, Gini de distribuição de terras ou percentuais de área em grandes propriedades), ocorrência de invasões de terra (eventos de conflito, possivelmente dos registros da Comissão Pastoral da Terra ou INCRA) e informação sobre assentamentos de reforma agrária implementados. Uma característica importante é que eles introduzem variáveis para captar a “vizinhança” ou contexto espacial: em particular, uma medida de ameaça local vinda de perto, operacionalizada como algo como o número (ou existência) de projetos de reforma agrária em municípios adjacentes (“nearby land reforms”)[24]. Ou seja, para cada município, verificaram se nos municípios contíguos (vizinhos diretos) houve implementação de reforma agrária em dado ano, interpretando isso como um choque externo percebido pelas elites fundiárias locais. Em termos de matriz de vizinhança, é provável que tenham usado contiguidade tipo queen (já que municípios se tocam em vértices também) ou pelo menos rook para definir quem é vizinho de quem. A análise considerou também a dimensão temporal (1988–2013), possivelmente usando modelos de painel, e incluiu controles socioeconômicos regionais. Para robustez, os autores relatam ter feito testes com defasagens espaciais adicionais e controle de efeitos regionais: por exemplo, eles agruparam erros por mesorregião e testaram incluir lags espaciais de invasões[25], o que indica preocupação em captar autocorrelação residual e dependência entre municípios próximos.

Estratégia de análise e diagnóstico espacial: Embora o trabalho seja quantitativo e inferencial (modelos estatísticos), podemos interpretá-lo sob a luz de diagnóstico espacial. Provavelmente, inicialmente os autores mapearam a distribuição de conflitos e de assentamentos para verificar onde se concentram (mesmo que não mostrado, isso é uma etapa comum). Eles notaram algo contraintuitivo: alguns dos municípios menos desiguais em terras eram bastante conflituosos[26], o que sugeria que não havia uma relação linear simples entre concentração fundiária e invasões. Ao invés disso, a análise exploratória deles indicou padrões condicionais: conflitos pareciam ocorrer onde reformas agrárias aconteceram próximo, alterando a dinâmica local. Em termos de diagnóstico, isso é detectar um padrão de interação espacial – a variável “assentamentos em vizinhos” parecia “catalisar” respostas diferentes conforme o contexto local de desigualdade. A formalização veio nos modelos: eles incluíram um termo de interação entre desigualdade fundiária local e indicador de reforma agrária em vizinhos. Os resultados mostraram um efeito condicional: onde não havia ameaças próximas (sem reforma agrária em torno), municípios com maior desigualdade de terras apresentavam mais invasões (provavelmente porque a grande concentração de terras gera muita demanda por reforma e poucas defesas coletivas, resultando em invasões bem-sucedidas)[27][22]. Entretanto, onde havia reforma agrária em municípios vizinhos, o padrão se invertia: nesses locais, uma alta desigualdade estava associada a menos invasões, sugerindo que as elites fundiárias, ao verem reformas acontecendo ao redor, se organizaram coletivamente (no âmbito regional) para reprimir ou prevenir invasões em seu território[28]. Ou seja, desencadeou-se um spillover territorial: as reformas agrárias vizinhas atuaram como gatilho para mobilização defensiva, “vacinando” ou blindando aquelas localidades contra invasões. Conceitualmente, um cluster de reforma agrária em torno alterou o padrão esperado no local central. Em termos de Moran local, poderíamos pensar que determinados municípios riquíssimos em terras, rodeados por vizinhos com políticas de reforma (situação algo análoga a um outlier “alto-baixo” invertido em termos de conflito), tiveram dinâmica singular. Os autores verificaram a robustez disso com vários testes, inclusive adicionando defasagens espaciais das variáveis dependentes para checar se a dependência espacial direta influenciava – confirmando que o mecanismo proposto se

mantinha[25].

Implicações e limites: Este estudo é exemplar para iniciantes por várias razões. Primeiro, ele mostra que padrões espaciais podem ser contraintuitivos e exigir teoria: a princípio esperaríamos que maior desigualdade sempre correlacionasse com mais conflito, mas o padrão real era não-linear e espacialmente condicionado. Isso ensina a evitar interpretações simplistas de um mapa ou correlação global – era preciso incluir a peça espacial (vizinhança) para resolver o quebra-cabeça. Em termos de política, os achados sugerem que conflitos rurais não ocorrem isoladamente: eles transbordam regionalmente. Uma implicação prática é que políticas de reforma agrária feitas de forma focalizada num município podem, paradoxalmente, provocar resistência organizada em municípios vizinhos ainda não reformados, talvez aumentando a violência em curto prazo[29][30]. Isso indica que programas de reforma devem considerar um planejamento regional integrado, antecipando reações das elites em áreas próximas. Em termos de limites, os autores reconhecem que seus resultados são condicionais ao contexto brasileiro e período específico – outros países com outros arranjos políticos poderiam apresentar dinâmicas diferentes[26]. Além disso, como todo estudo observacional, não há prova definitiva de causalidade micro (não se prova que foi porque vizinhos tiveram reforma que causou menos invasão; mas a correlação espaço-temporal é consistente com essa interpretação). Eles mitigaram isso incluindo efeitos fixos no tempo e espaço e testando outros mecanismos, mas sempre fica a ressalva: um padrão espacial detectado não elimina a necessidade de mais investigação causal. Por fim, do ponto de vista do MAUP, usar municípios é adequado para políticas nacionais, porém conflitos rurais podem ser localizados (fazendas específicas); agregações maiores (microrregiões) poderiam esconder focos locais intensos. O estudo assumiu que a escala municipal capturava bem o fenômeno, o que parece plausível dado que as mobilizações e repressões ocorrem em âmbito municipal/regional.

Resumindo este estudo em nossos quatro eixos: (1) Pergunta – a relação entre desigualdade de terra e conflito, e o papel modulador das reformas agrárias em vizinhos; (2) Dados/espacial – nível municipal no Brasil 1988-2013, contiguidade de municípios como vizinhança, variáveis de contexto espacial (assentamentos vizinhos), controles econômicos; (3) Análise – diagnóstico de padrão condicional (descoberta de cluster de conflitos em áreas de desigualdade alta sem vizinhos reformados e ausência de conflitos onde vizinhos tiveram reforma), modelagem com interação espacial e teste de autocorrelação (spatial lag), interpretações conceituais de elites reagindo a ameaças regionais; (4) Implicações – políticas de reforma devem considerar efeitos regionais e retaliações das elites, não basta olhar um município isolado; limites – possível viés se houver fatores regionais não observados, e a necessidade de generalizar para outros contextos com cautela.

4 Resultados Esperados

Além de atingir os objetivos de pesquisa já enunciados, o presente projeto pretende contribuir para a elaboração de políticas públicas que visem promover a igualdade de gênero e de raça, garantir os direitos dos povos indígenas e quilombolas, combater a violência no campo, preservar o meio ambiente e gerar renda para população rural.

Outro resultado importante será a consolidação de bancos de dados de diversas fontes (IBGE, STN, TSE, ISA, etc.) e outras informações que serão coletadas sobre as diferentes políticas e legislações fundiárias dos municípios foco do estudo. Os bancos consolidados serão utilizados não somente para realizar as análises do projeto e fundamentar as propostas de políticas públicas, como também servirão para o desenvolvimento dos trabalhos de mestrado e doutorado dos alunos de pós-graduação das instituições nas quais leciona-

mos.

Por fim, a partir dos resultados obtidos, serão produzidos ao menos 2 artigos a serem apresentados em fóruns qualificados nacionais e internacionais nas áreas de economia, sociologia e ciência política, para, posteriormente, serem publicados em revistas científicas nacionais e internacionais qualificadas e de alta circulação, como forma de difundir o conhecimento produzido pela pesquisa.

5 Etapas da Pesquisa e Cronograma

1. 01/04/2024 - Início das atividades de coleta de dados e atualização da base de dados e revisão atualizada da literatura;
2. 30/07/2024 - Conclusão da fase de coleta de dados e entrega da nova base de dados atualizados, testados e compatibilizados. Início da fase de modelagem econométrica e execução dos testes empíricos preliminares;
3. 30/01/2025 - Apresentação dos resultados preliminares do projeto de pesquisa;
4. 22/02/2025 - Entrega do relatório final da pesquisa.

6 Referências Bibliográficas

ALBERTUS, Michael, Thomas Brambor, e Ricardo Ceneviva. "Land inequality and rural unrest: theory and evidence from Brazil." *Journal of Conflict Resolution* 62, no. 3 (2018): 557-596.

ARRUDA, R. Número de invasões de terras é menor desde 2004. *O Estado de São Paulo*, abr 2011.

BAUMGARTNER, F.; JONES, B.; MORTENSEN, P. Punctuated equilibrium theory: explaining stability and change in public policymaking. In: SABATIER, P.; WEIBLE, C. (Eds.). *Theories of the policy process*. 3. ed. Boulder: Westview Press, 2014. p. 59-103.

CENEVIVA, R.; ARAUJO, R. T. O Efeito do Programa Bolsa Família sobre a Redução das Ocupações de Terra no Brasil. *X Encontro da Associação Brasileira de Ciência Política. Anais do X ENCONTRO DA ASSOCIAÇÃO BRASILEIRA DE CIÊNCIA POLÍTICA*. Belo Horizonte (MG): Associação Brasileira de Ciência Política, 2016.

CERQUEIRA, Daniel Ricardo de Castro (Coordenador), Paloma Palmieri Alves, Pedro Gomes Andrade, Milena Reis, Ana Camila Ribeiro Pereira, Karolina Chacon Armstrong, and Tais da Silva Figueiredo. "Atlas da violência no campo no Brasil: condicionantes socioeconômicos e territoriais." (2020).

CHIODA, L.; DE MELLO, J. M. P.; SOARES, R. R. Spillovers from conditional cash transfer programs: Bolsa Família and crime in urban Brazil. *Economics of Education Review*, v. 54, p. 306–320, 1 out. 2016.

CHITOLINA, L.; FOGUEL, M. N.; MENEZES-FILHO, N. A. The impact of the expansion of the bolsa familia program on the time allocation of youths and their parents. *Revista Brasileira de Economia - RBE, Revista Brasileira de Economia - RBE*. v. 70, n. 2, 2016.

CPT - Comissão Pastoral da Terra. *Conflitos no campo 2019*. Goiânia: CPT, 2019.

DUATE, G. B., Sampaio, B. e Sampaio, Y. "Programa Bolsa Família: impacto das transferências sobre os gastos com alimentos em famílias rurais." *Revista de economia e sociologia rural* 47 (2009): 903-918.

FERNANDES, B. M. The Occupation as a Form of Access to Land in Brazil: A Theoretical and Methodological Contribution. Em: MOYO, S.; YEROS, P. (Eds.). . *Reclaiming the Land: The resurgence of Rural movements in Africa, Asia and Latin America*. London: Zed Books, 2008.

FERNANDES, B. M. O MST não está em crise, mas, sim, os pequenos agricultores. *IHU On-Line*, Abr 2011.

FISZBEIN, A. et al. Conditional Cash Transfers: Reducing Present and Future Poverty. [s.l.] The World Bank Group, 2009.

FOGUEL, M. N. Modelo de Resultados Potenciais. Em: MENEZES-FILHO, N. (Ed.). . *Avaliação econômica de projetos sociais*. São Paulo: Fundação Itaú Social, 2016.

FOLHA DE SÃO PAULO. Bolsa Família esvazia MST, dizem analistas. *Folha de São Paulo*, 4 nov. 2007.

HIDALGO, F. D. et al. Economic Determinantes of Land Invasions. *The Review of Economics and Statistics*, v. 92, n. 3, p. 505–523, 2010.

Instituto Brasileiro de Geografia e Estatística (IBGE). *Censo Agropecuário 2006: Brasil, grandes regiões e Unidades da Federação*. Rio de Janeiro, IBGE, 2009.

MELO, R. M.S. e DUARTE, G.B. "Impacto do Programa Bolsa Família sobre a frequência escolar: o caso da agricultura familiar no Nordeste do Brasil." *Revista de Economia e Sociologia Rural* 48 (2010): 635-657.

ORELLANO, V. et al. Land Invasions, Insecure Property Rights and Production Decisions. *Journal of agricultural economics*, v. 66, n. 3, p. 660–671, 2016.

SABATIER, P. The need for better theories. In: SABATIER, P. A. (Ed). *Theories of the political process*. 2. ed. Boulder: Westview Press, 2007.

SILVA, Lígia Maria Osório. *Terras devolutas e latifúndio: efeitos da lei de 1850*. Centro de Memória Unicamp, 1996.

SIGAUD, L.; ROSA, M.; MACEDO, M. E. Ocupações de terra, acampamentos e demandas ao Estado: uma análise em perspectiva comparada. *Dados - Revista de Ciências Sociais*, v. 51, n. 1, p. 107–142, 2008.

ZUCCO Jr, Cesar. "The impacts of conditional cash transfers in four presidential elections (2002–2014)." *Brazilian Political Science Review* 9 (2015): 135-149.

7 Fontes de Dados

Para alcançar os objetivos geral e específicos descritos na seção anterior, o presente projeto pretende realizar análises estatísticas e gráficas utilizando diversas bases de dados secundários que incluem:

1. Censo Agropecuário (1996, 2006 e 2017)¹;

¹O censo agropecuário, do Instituto Brasileiro de Geografia e Estatística (IBGE), é a maior pesquisa estatística realizada no Brasil com a finalidade de produzir e disponibilizar exclusivamente informações sobre as características das atividades agropecuárias. Com periodicidade decenal, os dados são coletados diretamente em todos os estabelecimentos agrícolas, independente de seu tamanho, de sua forma jurídica,

2. Pesquisa de Orçamento Familiar (POF);
3. Censo IBGE (1991, 2000 e 2010);
4. Pesquisa Nacional por Amostra de Domicílios (PNAD e PNAD Contínua);
5. dados eleitorais do TSE (vários anos)
6. atlas Agropecuário do Brasil do Imaflora;
7. relatórios sobre Conflitos no Campo da CPT e DataLuta (Unesp);
8. estudo da Abrasco sobre agrotóxicos;
9. atlas de Violência no Campo do IPEA;
10. estudos da organização Espaço Feminista sobre Gênero e Terra;
11. estudos do IPAM e do Instituto Socioambiental (ISA) sobre regularização fundiária no Brasil e desmatamento;
12. FINBRA / STN - Banco de Dados de Finanças Municipais da Secretaria Nacional do Tesouro.

de empreender atividade comercial ou de subsistência, e de estar localizado em áreas rurais ou urbanas (IBGE, 2009). Evidentemente, a presente proposta de pesquisa valer-se-á sobretudo da análise dos dados da versão mais recente do Censo Agropecuário, publicado em 2017; mas, também de suas versões mais antigas, 1996 e 2006, já analisados em outros trabalhos do grupo de pesquisa.